

ニューラルネットワークにおける Affine レイヤの逆伝播導出

成分計算と行列微分の 2 つの視点から

Math & AI Note

2026 年 1 月 28 日

1 はじめに：問題の設定

本資料では、ニューラルネットワークの全結合層（Affine レイヤ）における誤差逆伝播法の導出を行う。順伝播の計算式は以下の通り定義する。

$$\mathbf{Y} = \mathbf{X}\mathbf{W} + \mathbf{B} \quad (1)$$

ここで、各変数の形状（シェイプ）は以下の通りとする。

- 入力 \mathbf{X} : $1 \times n$ の行ベクトル (x_1, \dots, x_n)
- 重み \mathbf{W} : $n \times m$ の行列 (w_{ij})
- バイアス \mathbf{B} : $1 \times m$ の行ベクトル (b_1, \dots, b_m)
- 出力 \mathbf{Y} : $1 \times m$ の行ベクトル (y_1, \dots, y_m)

損失関数を L とし、出力層からの勾配 $\frac{\partial L}{\partial \mathbf{Y}}$ は既知であるとする。このとき、入力 \mathbf{X} および重み \mathbf{W} に対する勾配 $\frac{\partial L}{\partial \mathbf{X}}, \frac{\partial L}{\partial \mathbf{W}}$ を導出する。

2 アプローチ 1：成分ごとの偏微分による導出

多変数関数の連鎖律（チェーンルール）を用い、成分ごとに計算してから行列の形に復元する方法である。

2.1 入力 X に関する微分

順伝播の第 j 成分 y_j は以下で表される。

$$y_j = \sum_{k=1}^n x_k w_{kj} + b_j \quad (2)$$

連鎖律より、入力の第 i 成分 x_i に対する勾配は、

$$\frac{\partial L}{\partial x_i} = \sum_{j=1}^m \frac{\partial L}{\partial y_j} \frac{\partial y_j}{\partial x_i} \quad (3)$$

ここで、 $\frac{\partial y_j}{\partial x_i} = w_{ij}$ であるため、

$$\frac{\partial L}{\partial x_i} = \sum_{j=1}^m \frac{\partial L}{\partial y_j} w_{ij} \quad (4)$$

この総和は、行ベクトル $\frac{\partial L}{\partial \mathbf{Y}}$ と行列 \mathbf{W} の転置 \mathbf{W}^T の積の第 i 成分に他ならない。したがって、

$$\frac{\partial L}{\partial \mathbf{X}} = \frac{\partial L}{\partial \mathbf{Y}} \mathbf{W}^T \quad (5)$$

となる。

2.2 重み W に関する微分

重みの (i, j) 成分 w_{ij} は y_j にのみ影響を与える。よって連鎖律は、

$$\frac{\partial L}{\partial w_{ij}} = \frac{\partial L}{\partial y_j} \frac{\partial y_j}{\partial w_{ij}} = \frac{\partial L}{\partial y_j} x_i \quad (6)$$

となる。これをすべての i, j について並べると、 $(n \times 1)$ の縦ベクトル \mathbf{X}^T と $(1 \times m)$ の横ベクトル $\frac{\partial L}{\partial \mathbf{Y}}$ の積となる。

$$\frac{\partial L}{\partial \mathbf{W}} = \mathbf{X}^T \frac{\partial L}{\partial \mathbf{Y}} \quad (7)$$

3 アプローチ 2：行列微分（全微分とトレース）による導出

行列計算における勾配を、全微分形式の線形近似係数として定義する方法である。成分計算を行わず、代数的な操作のみで導出が可能である。

3.1 行列微分の定義

スカラー関数 $f(\mathbf{X})$ の行列 \mathbf{X} による勾配 $\frac{\partial f}{\partial \mathbf{X}}$ を、以下の全微分 df を満たす行列 \mathbf{A} として定義する。

$$df = \text{tr}(\mathbf{A}^T d\mathbf{X}) \iff \frac{\partial f}{\partial \mathbf{X}} = \mathbf{A} \quad (8)$$

ここで $\text{tr}(\cdot)$ はトレース（対角和）を表す。

3.2 導出

損失関数 L の全微分は、出力勾配 $\mathbf{G} = \frac{\partial L}{\partial \mathbf{Y}}$ を用いて以下のように書ける。

$$dL = \text{tr}(\mathbf{G}^T d\mathbf{Y}) \quad (9)$$

ここで、順伝播式 $\mathbf{Y} = \mathbf{X}\mathbf{W} + \mathbf{B}$ の全微分をとる。

$$d\mathbf{Y} = (d\mathbf{X})\mathbf{W} + \mathbf{X}(d\mathbf{W}) + d\mathbf{B} \quad (10)$$

3.2.1 1. \mathbf{X} による勾配

\mathbf{W}, \mathbf{B} を固定し、 $d\mathbf{Y} = (d\mathbf{X})\mathbf{W}$ を代入する。

$$dL = \text{tr}(\mathbf{G}^T (d\mathbf{X})\mathbf{W}) \quad (11)$$

$$= \text{tr}(\mathbf{W}\mathbf{G}^T d\mathbf{X}) \quad (\because \text{トレースの巡回性 } \text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA})) \quad (12)$$

$$= \text{tr}((\mathbf{G}\mathbf{W}^T)^T d\mathbf{X}) \quad (13)$$

定義と比較して、 $\mathbf{A} = \mathbf{G}\mathbf{W}^T$ となるため、

$$\frac{\partial L}{\partial \mathbf{X}} = \frac{\partial L}{\partial \mathbf{Y}} \mathbf{W}^T \quad (14)$$

3.2.2 2. \mathbf{W} による勾配

\mathbf{X}, \mathbf{B} を固定し、 $d\mathbf{Y} = \mathbf{X}(d\mathbf{W})$ を代入する。

$$dL = \text{tr}(\mathbf{G}^T \mathbf{X}(d\mathbf{W})) \quad (15)$$

$$= \text{tr}(\mathbf{X}^T \mathbf{G}(d\mathbf{W}))^T \quad (\text{スカラーの転置は不変}) \quad (16)$$

$$= \text{tr}((\mathbf{X}^T \mathbf{G})^T d\mathbf{W}) \quad (17)$$

定義と比較して、

$$\frac{\partial L}{\partial \mathbf{W}} = \mathbf{X}^T \frac{\partial L}{\partial \mathbf{Y}} \quad (18)$$

4 まとめ

どちらのアプローチを用いても、結果は一致する。

- 成分計算アプローチ：直感的であり、微分の意味（感度解析）を理解しやすい。
- 行列微分アプローチ：記号操作のみで完結し、複雑な計算やテンソル計算において見通しが良い。